Laporan: Eksperimen End-to-End CNN Fashion-MNIST dengan MLflow

NAMA : IQFINA HAULA HALIKA

NIM : 123450076

KELAS : RA

Setup. Fashion-MNIST subset (10.000 train / 2.000 val / 2.000 test, diversi dengan DVC, md5 `8e47558d96213e622b898f69840c2dcf`). MLflow tracking server lokal (SQLite + folder artifact), experiment `fmnist-cnn-e2e`, 40 run (baseline, 20 trial Optuna, 3 seed, 12 run ablation, dan run pendukung). Std = simpangan baku sampel (n = 3 seed).

1. Hipotesis

- **H1.** Hyperparameter tuning (Optuna, 20 trial) menghasilkan konfigurasi yang lebih baik daripada baseline CNN default.
- **H2.** Augmentasi data (random crop + horizontal flip) meningkatkan generalisasi: akurasi test naik **dan** gap train–val mengecil.
- **H3.** Dropout mengurangi overfitting sehingga akurasi test naik.

Kriteria: sebuah komponen dianggap terbukti membantu bila selisih rata-rata test_acc positif dan lebih besar dari std antar-seed.

2. Metode

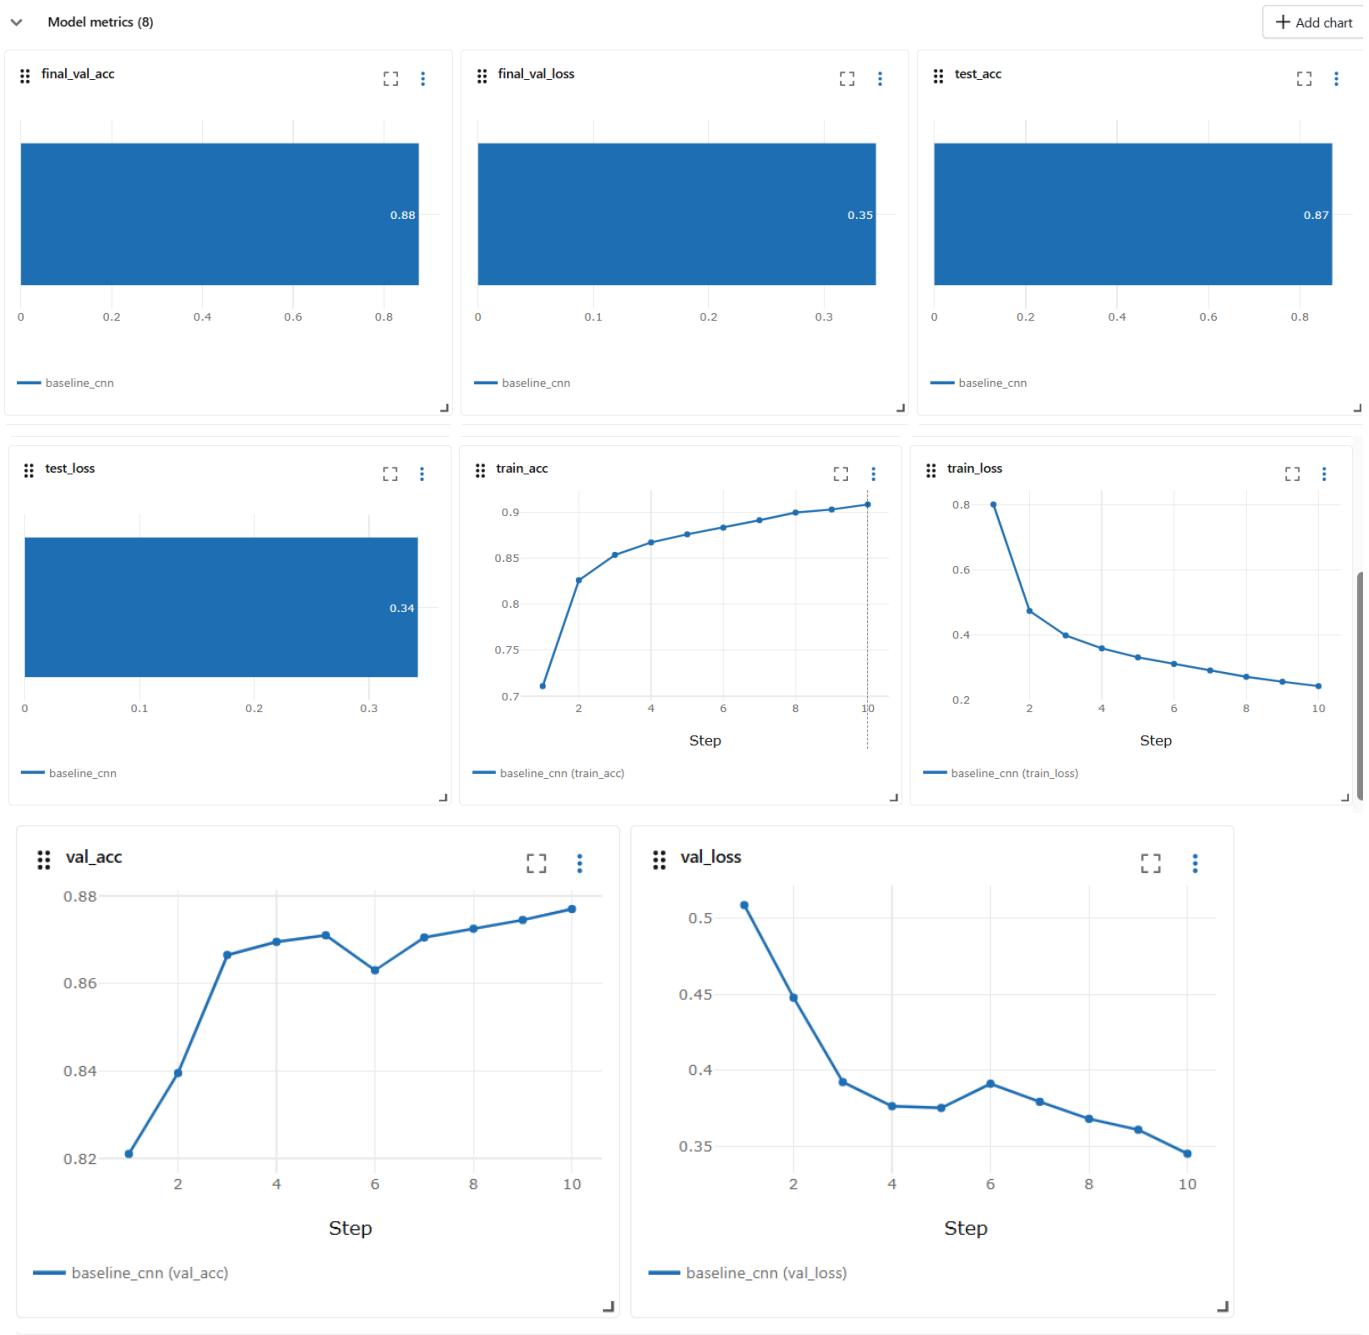
Tahap	Rincian
Baseline	CNN 2 blok konv (16 filter, hidden 64), tanpa augmentasi/dropout, lr 1e-3, batch 64, 10 epoch, seed 0
Tuning	Optuna TPE, 20 trial sebagai nested run, objektif val_acc, 8 epoch/trial, seed 0. Ruang cari: `n_filters`, `hidden`, `dropout`, `lr`, `batch_size`, `weight_decay` (augmentasi dibuat tetap aktif)
Seed	Konfigurasi terbaik, 15 epoch, seed 0/1/2
Ablation	Faktorial 2×2 (augmentasi × dropout), masing-masing 3 seed, 15 epoch
Registry	Model dengan val_acc tertinggi (bukan test) diregistrasi sebagai `fmnist-cnn`, alias `@champion`
DVC	Hash dataset dicatat sebagai param `dataset_md5` di setiap run

Konfigurasi terbaik (trial 11): `n_filters=64`, `hidden=64`, `dropout=0.161`, `lr=0.00217`, `batch_size=128`, `weight_decay=1.6e-6`, `augment=True`.

3. Hasil

3.1 Baseline

Baseline (seed 0): val_acc **0.8770**, test_acc **0.8710**, train_acc 0.9085. Kurva loss dan akurasi per epoch turun/naik stabil tanpa tanda divergensi.



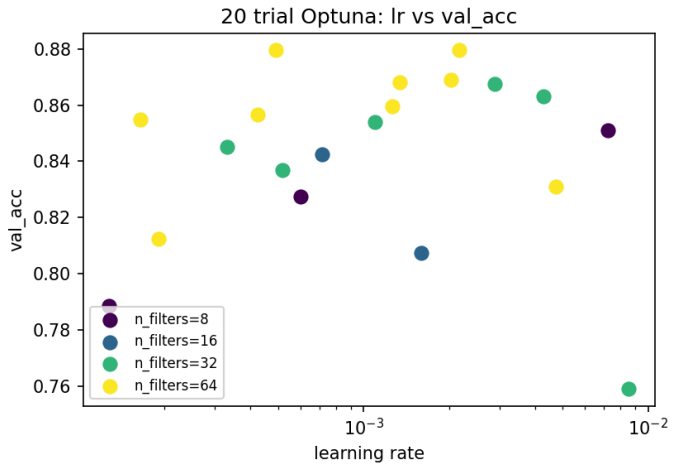
3.2 Tuning Optuna (20 trial)

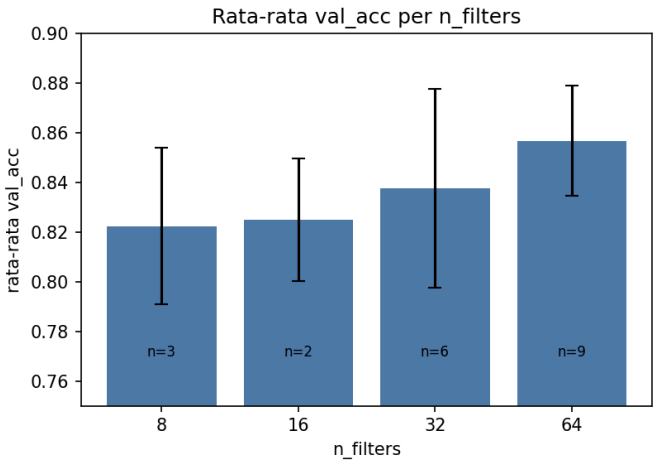
val_acc antar-trial berkisar **0.7590 – 0.8795** (rata-rata 0.8427). Dua trial seri di 0.8795 (trial 11 dan 17); trial 11 dipilih Optuna.

Trial	val_acc	n_filters	hidden	dropout	lr	batch
11	0.8795	64	64	0.161	0.00217	128
17	0.8795	64	64	0.109	0.00049	32
12	0.8690	64	64	0.209	0.00203	128
13	0.8680	64	64	0.162	0.00134	128

Trial	val_acc	n_filters	hidden	dropout	lr	batch
6	0.8675	32	64	0.263	0.00290	64

Rata-rata val_acc naik seiring `n_filters`: 8 → 0.822 (3 trial), 16 → 0.825 (2), 32 → 0.838 (6), 64 → 0.857 (9). Tren ini indikatif saja karena TPE tidak mengambil sampel secara acak merata.





3.3 Konfigurasi terbaik, 3 seed

Seed	val_acc	test_acc
0	0.8945	0.8970
1	0.8745	0.8820
2	0.8805	0.8890
mean ± std	**0.8832 ± 0.0103**	**0.8893 ± 0.0075**

3.4 Baseline vs tuned

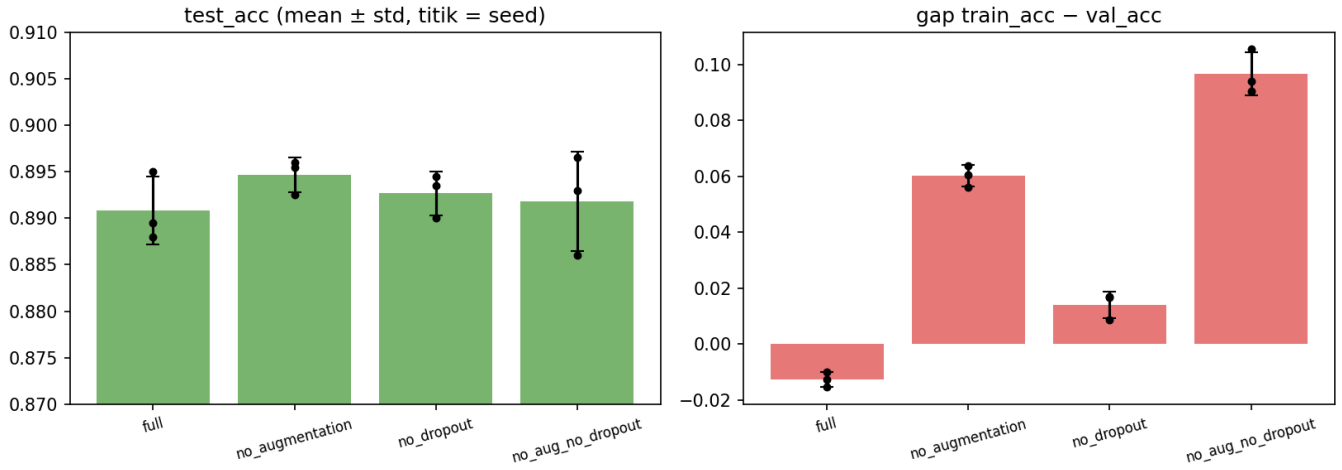
Model	val_acc	test_acc
Baseline (1 seed, 10 epoch)	0.8770	0.8710
Tuned (3 seed, 15 epoch)	0.8832 ± 0.0103	0.8893 ± 0.0075
Selisih	+0.62 poin	**+1.83 poin**

3.5 Ablation (3 seed)

Varian	val_acc	test_acc	train_acc	gap (train − val)
full (aug + dropout)	0.8838 ± 0.0067	0.8908 ± 0.0037	0.8712	−0.0127
no_augmentation	0.8923 ± 0.0066	0.8947 ± 0.0019	0.9525	0.0601
no_dropout	0.8807 ± 0.0071	0.8927 ± 0.0024	0.8948	0.0141
no_aug_no_dropout	0.8872 ± 0.0068	0.8918 ± 0.0053	0.9838	0.0967

Efek tiap komponen pada test_acc (poin):

Komponen	Saat komponen lain aktif	Saat komponen lain mati
Augmentasi (aktif − mati)	0.8908 − 0.8947 = **−0.39**	0.8927 − 0.8918 = **+0.09**
Dropout (aktif − mati)	0.8908 − 0.8927 = **−0.19**	0.8947 − 0.8918 = **+0.29**



Catatan penting untuk membaca tabel ini:

- Semua selisih test_acc (≤ 0.4 poin) lebih kecil dari std antar-seed (0.2–0.5 poin).
- Run ulang dengan seed yang sama pun bisa berbeda: `seed_1` (3 seed) test_acc 0.8820 vs `full_seed1` (ablation, konfigurasi sama) 0.8880, selisih 0.6 poin, kemungkinan karena nondeterminisme operasi GPU.
- Test set hanya 2.000 sampel, sehingga standard error akurasi ≈ 0.7 poin.
- train_acc dihitung saat training (dropout aktif, data teraugmentasi), jadi gap pada varian `full` bernilai negatif dan tidak sebanding persis dengan gap varian lain.

3.6 Model Registry

Model dari run `seed_0` (val_acc tertinggi di antara 3 seed, 0.8945) diregistrasi sebagai `fmnist-cnn` dengan alias `@champion`, dimuat lewat `models:/fmnist-cnn@champion`. Akurasi test hasil prediksi via alias (run `champion_predict`): ___ (isi dari metrik `champion_test_acc`; seharusnya ≈ 0.897, sama dengan `seed_0`).

4. Kesimpulan

H1 : Konfigurasi hasil tuning mencapai test_acc 0.8893 ± 0.0075 dibanding 0.8710 pada baseline (+1.83 poin, sekitar 2,4 std), dan val_acc naik 0.62 poin (masih dalam kisaran std). Dari 20 trial terlihat kapasitas model (`n_filters` lebih besar) paling konsisten terkait dengan val_acc yang lebih tinggi.

H2 : Augmentasi memperkecil gap train–val secara jelas (dari 0.097 menjadi 0.014 pada kondisi tanpa dropout), tetapi tidak menaikkan test_acc (−0.39 / +0.09 poin, di dalam noise). Jadi augmentasi mengurangi overfitting tanpa memberi keuntungan akurasi yang terbukti pada eksperimen ini.

H3: Dropout menurunkan gap (0.097 -> 0.060 tanpa augmentasi), namun efeknya pada test_acc (−0.19 / +0.29 poin) tidak lebih besar dari std.

Kesimpulan Perbaikan dari baseline ke model tuned lebih mungkin berasal dari kapasitas model, learning rate, dan batch size, bukan dari regularisasi (augmentasi/dropout): keempat varian ablation berada di 0.891–0.895, semuanya di atas baseline 0.871. Pada model `full`, train_acc (0.871) bahkan lebih rendah dari val_acc, sehingga regularisasi kuat dalam 15 epoch kemungkinan membuat model belum konvergen penuh. Dugaan ini belum diuji; langkah lanjutan adalah menambah epoch atau jumlah seed.

5. Keterbatasan

- Subset kecil dan test set 2.000 sampel (standard error ≈ 0.7 poin).
- Hanya 3 seed per varian; std dari n = 3 sangat kasar.
- Perbandingan H1 tidak sepenuhnya adil: baseline 1 seed/10 epoch, tuned 3 seed/15 epoch.
- Tuning memakai satu seed dan 8 epoch, sehingga trial terbaik bisa sebagian karena keberuntungan seed.
- Augmentasi dikunci aktif saat tuning, jadi konfigurasi terbaik tidak mempertimbangkan kemungkinan bahwa model tanpa augmentasi lebih baik.